



# Proyek Machine Learning End-to-End

Jejak Langkah Arsitek Data:  
Membangun Model Penilai Properti dari Nol






# Blueprint Proyek ML





# Langkah 1: Membingkai Masalah Bisnis



- **Tugas:** Membangun model regresi multivariat.
- **Sinyal Input:** Populasi, pendapatan median, usia bangunan.
- **Tujuan Akhir:** Menentukan kelayakan investasi properti berdasarkan prediksi harga yang presisi.



# Metrik Evaluasi: Diagnostik Performa Model

## RMSE (Root Mean Square Error)

Metrik Default / Regresi Umum

$$\sqrt{\frac{1}{m} \sum_{i=1}^m (h(\mathbf{x}^{(i)}) - y^{(i)})^2}$$

**Karakteristik:** Norma Euclidean

**Sensitivitas:** Sangat sensitif terhadap outlier (karena mengkuadratkan kesalahan besar).

## MAE (Mean Absolute Error)

Alternatif untuk Data Ekstrem

Penjumlahan Nilai Absolut

**Karakteristik:** Norma Manhattan

**Sensitivitas:** Lebih tangguh terhadap outlier (jarak blok kota).

**Kesimpulan:** Gunakan RMSE secara umum, beralih ke MAE jika dataset memiliki banyak distrik anomali.





# Langkah 2: Inspeksi Material Data

## Tampilan Data

|   | longitude | latitude | housing_median_age |
|---|-----------|----------|--------------------|
| 0 | -122.23   | 37.88    | 41.0               |
| 1 | -122.22   | 37.86    | 21.0               |
| 2 | -122.24   | 37.85    | 52.0               |
| 3 | -122.25   | 37.85    | 52.0               |
| 4 | -122.25   | 37.85    | 52.0               |

## Profil Data


- **Total Baris:** 20.640 instansi.
- **Tipe Data:** 9 fitur numerik (float64), 1 fitur kategorikal (object: ocean\_proximity).



**Peringatan Merah:** Atribut **total\_bedrooms** hanya memiliki **20.433 nilai non-null**. Terdapat 207 distrik kehilangan data.



# Membedah Distribusi Numerik




**1 Skala Berbeda:** Atribut memiliki rentang nilai yang sangat berbeda. Pendapatan median dibatasi (0.5 hingga 15, merepresentasikan puluhan ribu dolar). Membutuhkan *feature scaling*.

**2 Nilai Dibatasi (Capped):** Garis lonjakan ekstrem di sisi kanan grafik harga rumah. Model berisiko belajar bahwa harga tidak pernah melebihi angka \$500,000 ini.

**3 Tail-Heavy:** Banyak distribusi memanjang ke kanan. Kondisi ini mempersulit algoritma dalam mendeteksi pola.




# Menghindari Bias Pengintaian Data (Data Snooping)





# Langkah 3: Pemetaan Kepadatan & Harga



**Warna (Harga):** Gradien dari Biru (Murah) ke Merah (Mahal).

**Ukuran Lingkaran (Populasi):** Semakin besar radius, semakin padat penduduk.

**Hotspots:** Kluster harga tinggi jelas berpusat di Bay Area, Los Angeles, dan San Diego (Area pesisir laut).

**Insight:** Lokasi (kedekatan laut) dan kepadatan populasi adalah **prediktor kritis** untuk harga rumah.



# Sinyal Terkuat: Pendapatan vs Harga




## Korelasi

|               | sinyal  | value  | popallity | median_income |
|---------------|---------|--------|-----------|---------------|
| harga         |         | 0.3600 | 0.1275    | 0.3681        |
| data          |         | 0.9082 | -0.3112   | 0.8336        |
| populirsi     | -0.6879 |        | 0.0071    | 0.6871        |
| median_income |         |        |           | 0.687         |
| harga         | -0.3184 | 0.7359 | 0.19369   | 0.7285        |
| pendapatan    | 0.6801  | 0.3162 | -0.24761  | 0.6871        |
| harga         | -0.2222 | 0.0878 | -0.00070  |               |

**Korelasi positif terkuat** terhadap harga rumah.

## Scatter Plot




**Peringatan:** Distrik dengan nilai anomali horizontal ini idealnya dibersihkan agar model tidak mempelajari 'keanehan' data.





# Rekayasa Fitur (Feature Engineering)



**Pesan Inti:** Atribut mentah seringkali kurang informatif sebelum dikombinasikan dengan konteks atribut lainnya.




## Langkah 4: Persiapan Data (Strategi Nilai Hilang)




- Fokus:** Menangani kolom `total_bedrooms` yang kosong.

### Buang Baris (dropna)




Kehilangan sampel data distrik berharga. Tidak ideal untuk dataset kecil.

### Buang Kolom (drop)



Kehilangan sinyal potensial (rasio kamar sebelumnya terbukti penting).

### Imputasi Median (fillna)



Solusi optimal. Menggunakan SimpleImputer dari Scikit-Learn.

**Aturan Emas:** Median harus dihitung **HANYA** pada training set, lalu disimpan (statistics\_) untuk menambal nilai hilang pada test set dan data produksi baru.



# Anatomi API Scikit-Learn



## Estimators

Objek yang belajar dari data.  
Metode utama: **fit()**.  
(Contoh: imputer mempelajari nilai median).

## Transformers


Objek yang mengubah data berdasarkan parameter yang dipelajari.  
Metode utama: **transform()** dan **fit\_transform()**.

## Predictors

Objek penentu yang memberikan hasil akhir.  
Metode utama: **predict()** untuk prediksi dan **score()** untuk evaluasi performa.




# Mengonversi Kategori: Ordinal vs One-Hot





# Sintesis: Arsitektur Pipeline Persiapan Data



**Kesimpulan:** Proses persiapan ini sekarang bersifat reproduibel, modular, dan siap menangani aliran data produksi secara otomatis. Standar sejati seorang arsitek data.